

**Estudiante: Alejandra Pajón Julio. CC 1035859787**

Programa: Doctorado en medicina clínica - Facultad de medicina, Universidad de Antioquia

Título de la tesis: “Radiómica en resonancia magnética para la clasificación clínica de la enfermedad de Alzheimer a través de un modelo de inteligencia artificial”

### **Descripción de la arquitectura de los notebooks entregados**

En el repositorio de Github se entregan 9 notebooks, enumerados y descritos brevemente a continuación:

1. Exploración de datos: se realiza una exploración inicial de los datos de la cohorte 1 de la base de datos ADNI, con énfasis en la distribución de clases en cada visita. Se identifica disbalance de clases y se realiza una técnica de remuestreo
2. Transformación 2D ADNI1: Se transforman los datos tabulares en imágenes sintéticas para ser procesadas por redes convolucionales
3. Alex-net ADNI1: primer intento con una red pre-entrenada
4. Res-net ADNI1: segundo intento con una red pre-entrenada
5. ConvNet 4Class ADNI1: red convolucional entrenada desde cero para clasificación de 4 clases
6. ConvNet 2Class1 ADNI1: red convolucional entrenada desde cero para clasificación de 2 clases
7. ConvNet 2Class2 ADNI1: red convolucional entrenada desde cero para clasificación de 2 clases
8. Transformación 2D ADNI2: Se transforman los datos tabulares en imágenes sintéticas para ser procesadas por redes convolucionales
9. ConvNet 2Class2 ADNI2: red convolucional entrenada con técnica de transfer learning para clasificación de 2 clases

### **Descripción de la solución**

Con el propósito de facilitar la evaluación de los notebooks entregados, se realizará la descripción dividida por notebook.

#### **- Exploración de los datos:**

Como se describió en el documento de la primera entrega, para este proyecto se utilizaron datos de la base ADNI, una iniciativa internacional que busca facilitar la investigación en la enfermedad de Alzheimer. En este primer notebook se descargan los dos archivos en los que se almacenó esta información, en formato csv. Existen inconsistencias en la codificación de la variable 'VISCODE' para la cohorte ADNI1, por lo que se armonizan previo a la valoración de la distribución de clases.

El plan de análisis es transversal, por lo que se busca obtener información de una sola de las visitas de cada participante. Todas las visitas tienen disbalance significativo de clases, con subrepresentación significativa de la clase CDR 3. Se selecciona la visita de 24 meses y se decide considerar como una sola clase el puntaje de CDR 2 y 3.

Para afrontar el problema de distribución de clases, se divide la muestra en sets de entrenamiento y prueba, y se realiza un remuestreo con la técnica SMOTE en el set de entrenamiento.

- **Transformación 2D ADNI1:**

La información que se utiliza para el entrenamiento del modelo es tabular. Sin embargo, tiene la particularidad de ser toda en la misma unidad de medida, y se obtuvo de la misma manera a partir del análisis estructural de una adquisición volumétrica de resonancia magnética potenciada en T1; además, se sabe de antemano que existe correlación entre la atrofia de diferentes estructuras cerebrales, dadas las conexiones neuronales inter e intralobares. Por esto se decidió intentar una transformación de dicha información tabular en imágenes sintéticas. Para esto se utilizó un método publicado por Zhu et al., que calcula la distancia entre píxeles según correlación de Pearson o distancia euclidiana, y la diferencia de la distancia entre características y distancia entre píxeles a través de la distancia euclidiana o distancia de Manhattan. En este cuaderno se hace la transformación del set de prueba y set de entrenamiento de ADNI1, obtenido en el notebook previo, utilizando ambas técnicas para el cálculo de distancias y diferencia de distancias. Como no se espera que la relación entre las variables sea lineal, se decide entrenar los primeros modelos con las imágenes resultado de la técnica de análisis euclidiana.

- **Alex-net ADNI1:**

En este cuaderno iniciamos el entrenamiento de un modelo, utilizando transfer learning con un modelo pre-entrenado (Alex-net). Se descarga el set de imágenes de entrenamiento (obtenido del notebook previo) y las etiquetas, y se realiza codificación de las etiquetas. Se define el modelo para congelar las primeras capas, reemplazando la última por una capa entrenable, para clasificación en 4 clases, con repetición de 50 epochs. El entrenamiento de este modelo toma algún tiempo (30-40 min), por lo que para facilitar su evaluación se descargaron los pesos de la última capa posterior al entrenamiento. Las celdas de prueba del modelo utilizan dicha información extraída directamente de GitHub, por lo que no se requiere terminar el entrenamiento para evaluar el resto del notebook. El desempeño de este modelo no es bueno, aún cuando se le permite un número mucho mayor de epochs.

- **Res-net ADNI1:**

En este cuaderno se realiza un entrenamiento similar al previo, con una red pre-entrenada; en este caso resnet-50. El procedimiento fue muy similar, cambiando solo la arquitectura de la red. También es un entrenamiento que toma tiempo (2 horas aprox) para 50 epochs, por lo que también se descargaron los pesos de la última capa, para poder correr las celdas de prueba, sin tener que terminar el entrenamiento del modelo. El desempeño de este modelo tampoco fue bueno.

- **ConvNet 4Class ADNI1:**

Dado el pobre desempeño de los modelos pre-entrenados, se decidió entrenar una red convolucional desde cero, con pocas capas, con el fin de poder ajustar sus características. La red neuronal utilizada está compuesta por tres bloques de convolución, cada uno seguido de una normalización por lotes y funciones de activación ReLU. Sigue una capa de aplanamiento y, posteriormente, tres capas completamente conectadas. En las dos primeras capas completamente conectadas se utilizaron capas de dropout, como estrategia de mitigación del sobreajuste. Se utilizaron estrategias de transformación de las imágenes (RandomRotation, RandomAffine, ColorJitter y RandomResizedCrop), así como reescalado y normalización de las imágenes. Se configuran parámetros de entrenamiento como el número de épocas (75), un criterio de pérdida (CrossEntropyLoss), y un optimizador (Adam) con una tasa de aprendizaje de 0.001 y decaimiento de peso de  $1e-4$ . Por último, se implementa una técnica de Early Stopping para detener el entrenamiento si no hay mejora en la precisión de validación durante un número definido de épocas (paciencia de 10). El modelo se guarda si se alcanza una nueva mejor precisión.

A pesar de las estrategias implementadas, este modelo presentó buen desempeño en el entrenamiento, pero pobre desempeño en el set de prueba (nunca antes visto por el modelo), por lo que se considera que persiste un importante sobreajuste.

- **ConvNet 2Class1 ADNI1:**

Posterior a múltiples intentos de clasificación en 4 clases, con importante sobreajuste y pobre desempeño en el set de prueba, se decide intentar el entrenamiento de un modelo binario (enfermos vs sanos). Para esto se simplifican las clases, considerando CDR 0 y 0,5 como sano (0), y CDR 1, 2 y 3 como enfermo (1). La arquitectura del modelo y parámetros de entrenamiento son similares a los del notebook anterior, con disminución de la cantidad de capas completamente conectadas (2 capas) y modificación de la capa de salida para ajustarse a la tarea de clasificación binaria. Con la simplificación de las clases se obtuvo un mejor desempeño del modelo en el proceso de entrenamiento, el cual se conservó en niveles aceptables en el set de prueba.

- **ConvNet 2Class2 ADNI1:**

Se repitió el entrenamiento anterior, con el segundo set de imágenes, obtenido del análisis con correlación de Pearson y distancia de Manhattan. Los valores de desempeño del modelo son discretamente mayores a los obtenidos con el primer set de imágenes.

- **Transformación 2D ADNI1:**


En este notebook se realiza la exploración de datos de la cohorte 2 de ADNI, armonización, partición, remuestreo y transformación a imágenes sintéticas, similar al procedimiento que se llevó a cabo con los datos de la cohorte 1.

- **ConvNet 2Class2 ADNI2:**

En este notebook se entrenó una red neuronal idéntica a la descrita para la cohorte 1, utilizando los pesos obtenidos del entrenamiento previo (transfer learning), con los datos de la cohorte 2 de ADNI, obteniendo resultados moderadamente buenos.

### Descripción de los resultados

Transformación de los datos tabulares en imágenes:



Este es un ejemplo de las imágenes que se obtuvieron con el proceso descrito de transformación 2D.

#### Cohorte ADNI 1

Red convolucional binaria (distancia euclidiana):

- Accuracy alcanzado en entrenamiento: 92,57%
- Accuracy: 0.7568
- Precision: 0.7363
- Recall: 0.7568

Red convolucional binaria (Correlación de Pearson-Manhattan):

- Accuracy alcanzado en entrenamiento: 87,84%
- Accuracy: 0.8108
- Precision: 0.8179
- Recall: 0.8108
- Especificidad: 0.8537

#### Cohorte ADNI 2

Red convolucional binaria (Correlación de Pearson - Manhattan):

- Accuracy alcanzado en entrenamiento: 85,62%
- Accuracy: 0.6577
- Precision: 0.8851
- Recall: 0.6577
- Especificidad: 0.6391

### Análisis:

El desempeño de los modelos pre-entrenados con estructuras complejas (resnet50, Alexnet), fue mucho menor al esperado, sin lograr alcanzar accuracy de más de 30%. Es probable que esto se deba a las características específicas de las imágenes que se utilizaron para entrenar dichas redes (ej. imágenes en donde se pueden identificar patrones o formas), las cuales difieren del set de imágenes que se obtuvo en la transformación descrita.

El mejor desempeño obtenido fue en el set de imágenes creado utilizando correlación de Pearson y distancia de Manhattan, en la cohorte ADNI 1. Este es un hallazgo interesante, ya que, por la distribución de la atrofia en la enfermedad de Alzheimer, no se esperaba que los volúmenes de las diferentes estructuras cerebrales tuviesen correlación lineal entre sí.

Al utilizar la técnica de transfer learning en la segunda cohorte (ADNI2), sin embargo, se observa disminución en los parámetros de desempeño. Existen múltiples explicaciones para esto; una causa de esto puede deberse a la diferencia en los parámetros de la adquisición de las imágenes de resonancia magnética (para ADNI1 fue en resonador de 1.5T y para ADNI2 en resonador de 3T), el marcado desbalance de clases evidente en ADNI2 (incluso mayor que en ADNI1), diferencias en el etiquetado de las observaciones (diferentes cohortes pueden haber sido evaluadas por equipos clínicos diferentes), etc. Si bien la estrategia de transfer learning no tuvo el éxito esperado, la información obtenida es de importancia para futuros análisis.